

# **Analiza cen noclegów Airbnb w Barcelonie, Berlinie i Budapeszcie**

**Autor: Małgorzata Dąbek  
Katowice 2026**

## **Spis treści**

1. Wstęp.....	3
2. Cel analizy .....	3
3. Pytania badawcze .....	3
4. Hipotezy .....	4
4. Źródło danych .....	4
5. Przygotowanie i czyszczenie danych .....	6
6. Analiza .....	10
7. Wnioski .....	14
8. Bibliografia.....	16
9. Spis rysunków .....	17

## 1. Wstęp

W dzisiejszych czasach wzrasta popularność turystycznych wynajmów krótkoterminowych. Jednym z najpopularniejszych platform oferujących noclegi w wielu miastach świata jest platforma Airbnb.

W projekcie przeanalizowano usługi noclegowe z platformy Airbnb w Barcelonie, Berlinie i Budapeszcie. Analiza cen za pobyt, typu zakwaterowania, statusu gospodarza (superhost), oceny gości, oceny czystości oraz cech lokalizacyjnych (np.: odległość od centrum miasta, stacji metra) pozwala podejmować właściwe decyzje nie tylko turystom, ale też gospodarzom czy inwestorom.

## 2. Cel analizy

Celem niniejszej pracy jest analiza czynników wpływających na poziom cen noclegów oferowanych na platformie Airbnb w Barcelonie, Berlinie oraz Budapeszcie. Analiza została oparta o zbiór danych Airbnb Prices in European Cities z platformy kaggle.com<sup>1</sup>. Praca ma na celu zidentyfikowanie najważniejszych zmiennych determinujących wysokość ceny wynajmu, takich jak typ obiektu, liczba sypialni, oceny użytkowników, status *superhost* czy odległość od centrum miasta i komunikacji miejskiej. Dodatkowym celem jest porównanie poziomu cen pomiędzy poszczególnymi miastami oraz sprawdzenie, czy zależności między cechami ofert a ceną są podobne w różnych lokalizacjach.

## 3. Pytania badawcze

Poniżej zadano pytania, na które analiza dać odpowiedzi:

1. Które miasto jest najdroższe?
2. Jaka jest średnia cena noclegów w poszczególnych miastach?
3. W których miastach i dniach tygodnia (dni robocze vs. Weekendy) noclegi są najdroższe?
4. Jak typ noclegu wpływa na cenę?
5. Jaki jest rozkład poszczególnych typów noclegu w poszczególnych miastach? Których typów noclegów jest najwięcej w poszczególnych miastach?
6. Czy cena wpływa na satysfakcję gości?
7. Czy lokalizacja faktycznie uzasadnia wyższą cenę?
8. Jaka jest średnia cena noclegów mających status *Superhosta* w porównaniu do noclegów bez tego statusu?

---

<sup>1</sup> <https://www.kaggle.com/datasets/thedevastator/airbnb-prices-in-european-cities/data> [dostęp: 09.02.2026].

## 4. Hipotezy

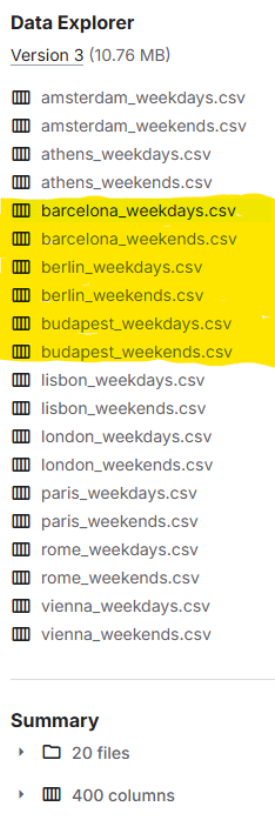
Założono, że:

1. im bliżej centrum miasta tym noclegi droższe.
2. w weekendy ceny noclegów są wyższe niż w dni robocze.
3. najdroższe są całe domy/apartamenty.

## 4. Źródło danych

Dane pochodzą ze strony *kaggle.com*<sup>2</sup> i zostały udostępnione w oparciu o licencję CC0: Public Domain, która umożliwia wykorzystanie ich w projekcie. Autor, który zebrał dane, nie został podany. Nie wskazano również, którego roku dotyczą dane. Wiadomo jedynie, że zostały one opublikowane na stronie internetowej dwa lata temu.

W bazie są dane dotyczące noclegów zlokalizowanych w 10 miastach europejskich (Amsterdam, Ateny, Barcelona, Berlin, Budapeszt, Lizbona, Londyn, Paryż, Rzym, Wiedeń) podzielonych na dni robocze i weekendy. W sumie jest 20 plików zawierających 400 kolumn (rysunek 1). Spośród wszystkich plików wybrano 6 dotyczących noclegów w Barcelonie, Berlinie i Budapeszcie w dni robocze i weekendy.



Rysunek 1. Pliki i atrybuty danych niezbędnych do analizy

---

<sup>2</sup> Tamże.

Poniżej ukazano parę atrybutów i rekordów wybranej bazy danych (rysunek 2).

**barcelona\_weekdays.csv** (319.68 kB)

Detail Compact Column

20 of 20 columns

### About this file

Suggest Edits

This dataset provides information on Airbnb prices in Barcelona, including room type, cleanliness rating, guest satisfaction score, number of bedrooms, and distance from the city centre

# Id	# realSum Real Sum	△ room_type Room Type	✓ room_shared Room Shared	✓ room_private Room Private	# person Person Count
		Private room 76% Entire home/apt 23% Other (8) 1%	 true 8 1% false 1547 99%	 true 1185 76% false 370 24%	
0	1554				2
0	474.3174994763423	Entire home/apt	False	False	4.0
1	169.89782856610887	Private room	False	True	2.0
2	161.98477901645447	Private room	False	True	4.0
3	367.9568040589289	Entire home/apt	False	False	3.0
4	196.89529173551793	Private room	False	True	3.0
5	330.9516605767216	Entire home/apt	False	False	3.0
6	141.27120813647682	Private room	False	True	3.0
7	173.3888798380152	Private room	False	True	2.0
8	225.7546489166104	Private room	False	True	4.0

Rysunek 2. Atrybuty i rekordy wybranej bazy danych

## 5. Przygotowanie i czyszczenie danych

Ze strony *kaggle.com* ściągnięto pliki .csv (rysunek 3).

```
,realSum,room_type,room_shared,room_private,person_capacity,host_is_superhost,multi,biz,cleanliness_rating,guest_satisfaction,overall,bedrooms,dist,metro_dist,attr_index,rest_index,rest_index_norm,lng,lat
0,474.3174994763423,Entire home/apt,False,False,4.0,False,0.1,10.0,91.0,1.1,111996477976483,0.6304909460189917,526.4694202447247,17.942926962147965,915.5870827687069,20.1548895790265,2.17566,41.39624
1,169.89782856610887,Private room,False,True,2.0,True,1.0,10.0,88.0,1.1,751839016015303,0.1240171716446693,320.12752551210633,10.910462389566375,794.2773503129439,17.48448901470924,2.14906,41.38714
2,161.98477901645447,Private room,False,True,4.0,False,0.1,9.0,88.0,1.1,6704928969848183,0.08032197629455128,344.07393595254723,11.72659467952677,840.6736172628903,18.50581364330432,2.15357,41.37859
3,367.9568040589289,Entire home/apt,False,False,3.0,False,0.1,10.0,91.0,1.1,4756465180822207,0.09310666464817329,400.0574494539389,13.63460311308965,946.5898839190221,20.837356649155502,2.16839,41.3739
4,196.89529173551793,Private room,False,True,3.0,False,1.0,9.0,91.0,1.1,8554523875617355,0.27248604884480077,346.04224486126867,11.793677821737987,792.2960390372838,17.440874255682875,2.15238,41.37699
5,330.9516605767216,Entire home/apt,False,False,3.0,False,0.1,9.0,100.0,2.2,56561144538374,0.7012904474128752,391.0874019298987,13.328889426061002,525.5139017194555,11.56817834232667,2.18197,41.40842
6,141.27120813647682,Private room,False,True,3.0,False,0.1,9.0,86.0,1.1,6483044059080145,0.08942672542334265,342.5968430512519,11.676252971110106,820.9265676695487,18.07112036585524,2.15342,41.37912
7,173.3888798380152,Private room,False,True,2.0,False,0.0,9.0,96.0,1.1,474227862111036,0.590519404106601,448.4056158207572,15.282386601578585,752.7588763697871,16.570539622496806,2.18195,41.39691
8,225.7546489166104,Private room,False,True,4.0,False,1.0,9.0,84.0,1.1,9626548851516769,0.356133898715912,791.8737456586989,26.9883344316406,1885.5346272618576,41.50642022490588,2.17742,41.3805
9,150.58067819489375,Private room,False,True,2.0,False,1.0,9.0,91.0,1.1,819599926166855,0.2856012819672106,361.1992095620816,12.310251624767464,806.236687179304,17.74775082619196,2.157,41.373999999999995
10,194.33518746945327,Private room,False,True,2.0,False,1.0,9.0,84.0,1.1,011673847628958,0.371659717830789,530.5220848322261,18.08104830766091,1189.4978129428239,26.184507760702463,2.16895,41.37806
11,190.84413619754693,Private room,False,True,2.0,True,1.0,10.0,98.0,1.2,214067238602181,0.37601684835938803,589.7332964686169,20.09906189948204,647.2490052387491,14.247942632909757,2.17853,41.40602
12,387.5066911816044,Private room,False,True,2.0,False,1.0,9.0,91.0,1.1,5493718616401952,0.5760611356393729,394.1508318300387,13.433296057933983,780.6114289479832,17.183660026085313,2.18778,41.3911
13,248.56285055973186,Private room,False,True,2.0,True,0.0,10.0,95.0,1.0,7409052928219434,0.2701075756829207,566.5604594901032,19.31236158592515,1145.7439394800836,25.221350345211707,2.17806,41.38993
14,136.38373635580794,Private room,False,True,2.0,False,0.1,9.0,84.0,1.1,6881515652165777,0.302537308785363,342.3747475635525,11.668683596860914,826.0136877793922,18.183103476748972,2.15326,41.37865
15,117.99753299043451,Private room,False,True,2.0,False,1.0,8.0,84.0,1.2,5774670084852263,0.05049220531962998,289.92047271053934,9.880957310414166,590.0639134566637,12.989122765170771,2.14385,41.37486
16,150.58067819489375,Private room,False,True,2.0,False,1.0,8.0,87.0,1.0,25032051605637906,0.2528176432539952,574.4172772437153,19.577067261739323,1438.2013104025184,31.65923717044896,2.16704,41.387409999999996
17,1041.4969627853934,Entire home/apt,False,False,4.0,False,0.0,10.0,99.0,3.1,888740219991341,0.1377725911348623,1335.1308497481652,45.503412735360904,781.267568458616,17.1981033676104108,2.173,41.403999999999996
18,474.3174994763423,Entire home/apt,False,False,4.0,False,0.1,10.0,91.0,1.1,1955935341570885,0.579910583961592,512.849988503535,17.478754762204172,862.6687048852137,18.989983215790633,2.1771700000000003,41.39646
19,440.80340726604135,Entire home/apt,False,False,4.0,False,0.1,9.0,92.0,1.1,6181542700344187,0.5942830541189548,461.32144855040303,15.722579012403944,934.6734138705079,20.575038468264072,2.16091,41.4
20,111.01543044662182,Private room,False,True,2.0,False,0.1,9.0,90.0,1.1,6689209872198028,0.30708937902139494,1048.128673814189,35.72191568588916,795.9437787908979,17.521172234248493,2.173,41.402
21,691.9263620918379,Entire home/apt,False,False,4.0,True,0.1,10.0,98.0,2.1,0681015103265317,0.7836815814257695,555.112245870443,18.919120656271556,1006.2999901054147,22.151759855128542,2.1705200000000002,41.39675
22,141.27120813647682,Private room,False,True,2.0,False,1.0,8.0,89.0,1.1,7747744250904425,0.43944787683058845,356.5515528368028,12.151851987561471,795.057934191469,17.501672068265727,2.16554,41.37151
23,181.76740289059043,Private room,False,True,2.0,False,1.0,9.0,89.0,1.0,8936410295617603,0.24152580198231396,904.7590649943944,30.835648182546784,2068.9162590164688,45.543214330453104,2.17594,41.38044
```

Rysunek 3. Przykładowy plik .csv z bazy danych

Zostały one następnie zaimportowane do programu Power BI (rysunek 4). Dane w nich zawarte zostały oczyszczone, przekształcone i połączone w Power Query (rysunek 5). Na początku zamieniono kropki na przecinki, zmieniono typ danych oraz przetłumaczono angielskie nazwy na polskie.

	realSum	room_type	room_shared	room_private	person_capacity	host_is_superhost	multi	biz
1	0 474.3174994763423	Entire home/apt	FALSE	FALSE	4.0	FALSE	0	FALSE
2	1 169.89782856610887	Private room	FALSE	TRUE	2.0	TRUE	1	FALSE
3	2 161.98477901645447	Private room	FALSE	TRUE	4.0	FALSE	0	FALSE
4	3 367.9568040589289	Entire home/apt	FALSE	FALSE	3.0	FALSE	0	FALSE
5	4 196.89529173551793	Private room	FALSE	TRUE	3.0	FALSE	1	FALSE
6	5 330.9516605767216	Entire home/apt	FALSE	FALSE	3.0	FALSE	0	FALSE
7	6 141.27120813647682	Private room	FALSE	TRUE	3.0	FALSE	0	FALSE
8	7 173.3888798380152	Private room	FALSE	TRUE	2.0	FALSE	0	FALSE
9	8 225.7546489166104	Private room	FALSE	TRUE	4.0	FALSE	1	FALSE
10	9 150.58067819489375	Private room	FALSE	TRUE	2.0	FALSE	1	FALSE
11	10 194.33518746945327	Private room	FALSE	TRUE	2.0	FALSE	1	FALSE
12	11 190.84413619754693	Private room	FALSE	TRUE	2.0	TRUE	1	FALSE
13	12 387.5066911816044	Private room	FALSE	TRUE	2.0	FALSE	1	FALSE
14	13 248.56285055973186	Private room	FALSE	TRUE	2.0	TRUE	0	FALSE
15	14 136.38373635580794	Private room	FALSE	TRUE	3.0	FALSE	0	FALSE
16	15 117.99753299043451	Private room	FALSE	TRUE	2.0	FALSE	1	FALSE
17	16 150.58067819489375	Private room	FALSE	TRUE	2.0	FALSE	1	FALSE
18	17 1041.4969627853934	Entire home/apt	FALSE	FALSE	6.0	TRUE	0	FALSE
19	18 474.3174994763423	Entire home/apt	FALSE	FALSE	4.0	FALSE	0	FALSE
20	19 440.80340726604135	Entire home/apt	FALSE	FALSE	4.0	FALSE	0	FALSE
21	20 111.01543044662182	Private room	FALSE	TRUE	2.0	FALSE	0	FALSE
22	21 691.9263620918379	Entire home/apt	FALSE	FALSE	4.0	TRUE	0	FALSE
23	22 141.27120813647682	Private room	FALSE	TRUE	2.0	FALSE	1	FALSE
24	23 181.76740289059043	Private room	FALSE	TRUE	2.0	FALSE	1	FALSE
25	24 190.84413619754693	Private room	FALSE	TRUE	2.0	FALSE	1	FALSE
26	25 230.17664719435845	Private room	FALSE	TRUE	3.0	TRUE	1	FALSE
27	26 170.13056531756928	Private room	FALSE	TRUE	2.0	FALSE	0	FALSE
28	27 237.39148648963155	Private room	FALSE	TRUE	2.0	FALSE	0	FALSE
29	28 387.5066911816044	Private room	FALSE	TRUE	2.0	FALSE	0	FALSE
30	29 143.36583889962063	Private room	FALSE	TRUE	2.0	FALSE	1	FALSE
31	30 515.0464309819163	Entire home/apt	FALSE	FALSE	5.0	FALSE	0	FALSE
32	31 139.87478762771428	Private room	FALSE	TRUE	2.0	TRUE	1	FALSE
33	32 150.58067819489375	Private room	FALSE	TRUE	2.0	FALSE	1	FALSE
34	33 159.65741150185025	Private room	FALSE	TRUE	2.0	FALSE	0	FALSE
35	34 229.24570018851674	Private room	FALSE	TRUE	2.0	FALSE	1	FALSE
36	35 156.1663602299439	Private room	FALSE	TRUE	2.0	FALSE	1	FALSE

Rysunek 4. Dane po zaimportowaniu do Power Query

ID_miasto	ID_obiektu	ID_typ_dnia	ID_lokalizacji	ID_oceny	Kwota_noclegu	Opłata_dodatkowa	Całkowita_cena_noclegu	Kategoria_ceny	Blisko_centrum	Blisko_metra	Ocena_czystości	Ocena_satisfakcji_gości
3	2850	1	3169	30	142,41	18,18	160,59	Tani	Nie	Tak	10	100
3	2862	1	3179	30	129,95	25,28	155,23	Tani	Nie	Tak	10	100
3	2872	1	3188	30	180,24	46,13	226,37	Tani	Tak	Tak	10	100
3	2876	1	3192	30	165,91	26,65	192,56	Tani	Nie	Tak	10	100
3	2885	1	3200	30	158,39	14,15	172,54	Tani	Nie	Tak	10	100
3	2896	1	3209	30	148,75	52,05	200,8	Tani	Tak	Tak	10	100
3	2901	1	3212	30	208,91	4,94	213,85	Tani	Nie	Tak	10	100
3	2904	1	3215	30	164,03	4,86	168,89	Tani	Nie	Tak	10	100
3	2927	1	3232	30	161,44	50,95	212,39	Tani	Tak	Tak	10	100
3	2946	1	3245	30	231,94	29,97	261,91	Tani	Tak	Tak	10	100
3	2947	1	3246	30	145,93	32,51	178,44	Tani	Nie	Tak	10	100
3	2965	1	3260	30	151,57	6,69	158,26	Tani	Nie	Nie	10	100
3	2970	1	3264	30	154,86	14,27	169,13	Tani	Nie	Tak	10	100
3	2978	1	3272	30	185,65	53,96	239,61	Tani	Tak	Tak	10	100
3	2992	1	3296	30	92,82	52,64	145,46	Tani	Tak	Tak	10	100
3	2998	1	3289	30	113,74	50	163,74	Tani	Tak	Tak	10	100
3	3000	1	3290	30	416,41	32,77	449,18	Drogi	Tak	Tak	10	100
3	3004	1	3293	30	174,37	74,74	249,11	Tani	Tak	Tak	10	100
3	3007	1	3296	30	757,16	47,92	805,08	Drogi	Tak	Tak	10	100
3	3013	1	3301	30	204,92	22,54	227,46	Tani	Nie	Tak	10	100
3	3021	1	3307	30	365,42	65,61	431,03	Drogi	Tak	Tak	10	100
3	3022	1	3308	30	288,10	8,48	296,58	Tani	Nie	Nie	10	100
3	3024	1	3310	30	270,71	54,27	324,98	Drogi	Tak	Tak	10	100
3	3025	1	3311	30	118,91	14,99	133,9	Tani	Nie	Tak	10	100
3	3030	1	3332	30	130,19	31,6	161,79	Tani	Nie	Tak	10	100
3	3052	1	3307	30	266,72	65,61	332,33	Drogi	Tak	Tak	10	100
3	3054	1	3335	30	149,93	13,26	163,19	Tani	Nie	Tak	10	100
3	3078	1	3356	30	211,26	28,19	239,45	Tani	Nie	Tak	10	100
3	3079	1	3357	30	162,38	50,61	212,99	Tani	Nie	Tak	10	100
3	3083	1	3361	30	104,34	18,53	122,87	Tani	Nie	Tak	10	100
3	3084	1	3362	30	87,42	15,45	102,87	Tani	Nie	Tak	10	100
3	3086	1	3364	30	162,38	4,13	166,51	Tani	Nie	Nie	10	100
3	3087	1	3365	30	255,21	24,61	279,82	Tani	Nie	Tak	10	100
3	3098	1	3375	30	205,62	4,08	209,7	Tani	Nie	Nie	10	100
3	3121	1	80	30	382,81	56,67	439,48	Drogi	Tak	Tak	10	100
3	3142	1	3411	30	360,01	31,2	391,21	Drogi	Nie	Tak	10	100
3	3146	1	3415	30	472,34	45,89	518,23	Drogi	Tak	Tak	10	100
2	2151	1	2430	30	212,44	10,68	223,12	Tani	Nie	Tak	10	100

Rysunek 5. Dane po oczyszczeniu, przekształceniu i połączeniu w Powe Query

Stworzono również tabelę faktów i tabele wymiarów (rysunek 6):

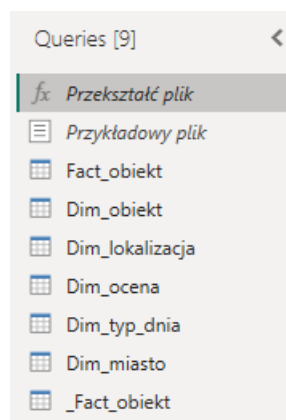
### 1) Tabela faktów:

- Fact\_obiekt – zawierająca ceny, oceny, czystość, status Superhosta, lokalizację i typ obiektu.

### 2) Tabele wymiarów:

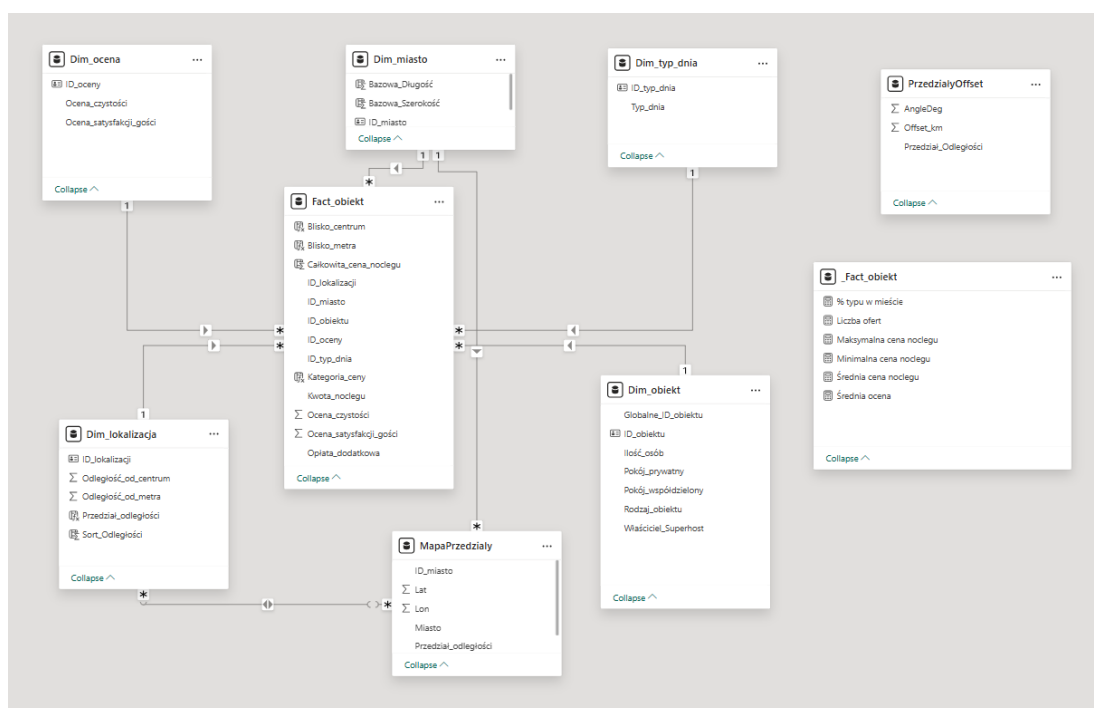
- Dim\_miasto
- Dim\_lokalizacja (odległość od centrum)
- Dim\_typ\_dnia
- Dim\_obiekt
- Dim\_ocena

Taki model umożliwił analizę danych w sposób wielowymiarowy.



Rysunek 6. Tabela faktów i tabelę wymiarów

Następnie w Power BI w zakładce widok modelu stworzono relacje między tabelami (model gwiazdy) (rysunek 7).



Rysunek 7. Model gwiazdy

Dodano również kolumny obliczeniowe i miary niezbędne do prawidłowej wizualizacji danych (rysunek 8).



Całkowita_cena_noclegu	Kategoria_ceny	Blisko_centrum	Blisko_metra	Ocena_czystości	Ocena_satysfakcji_gości
160,59	Tani	Nie	Tak	10	100
155,23	Tani	Nie	Tak	10	100
226,37	Tani	Tak	Tak	10	100
192,56	Tani	Nie	Tak	10	100
172,54	Tani	Nie	Tak	10	100
200,8	Tani	Tak	Tak	10	100
213,85	Tani	Nie	Tak	10	100
168,89	Tani	Nie	Tak	10	100
212,39	Tani	Tak	Tak	10	100
261,91	Tani	Tak	Tak	10	100
178,44	Tani	Nie	Tak	10	100
158,26	Tani	Nie	Nie	10	100
169,13	Tani	Nie	Tak	10	100
239,61	Tani	Tak	Tak	10	100
145,46	Tani	Tak	Tak	10	100
163,74	Tani	Tak	Tak	10	100
449,18	Drogi	Tak	Tak	10	100
249,11	Tani	Tak	Tak	10	100
805,08	Drogi	Tak	Tak	10	100
227,46	Tani	Nie	Tak	10	100
431,03	Drogi	Tak	Tak	10	100
296,58	Tani	Nie	Nie	10	100
324,98	Drogi	Tak	Tak	10	100
133,9	Tani	Nie	Tak	10	100
161,79	Tani	Nie	Tak	10	100
332,33	Drogi	Tak	Tak	10	100
163,19	Tani	Nie	Tak	10	100
239,45	Tani	Nie	Tak	10	100
212,99	Tani	Nie	Tak	10	100
122,87	Tani	Nie	Tak	10	100
102,87	Tani	Nie	Tak	10	100
166,51	Tani	Nie	Nie	10	100
279,82	Tani	Nie	Tak	10	100
209,7	Tani	Nie	Nie	10	100
439,48	Drogi	Tak	Tak	10	100
391,21	Drogi	Nie	Tak	10	100
518,23	Drogi	Tak	Tak	10	100
222,12	Tani	Nie	Tak	10	100

Rysunek 8. Kolumny obliczeniowe i miary dodane do modelu

W analizie wykorzystano miary DAX m.in.:

- Średnia cena noclegu,
- Średnia ocena,
- Liczba ofert,
- Maksymalna i minimalna cena noclegu,
- Udział procentowy typów obiektów w miastach.


## 6. Analiza

W programie Power BI stworzono dashboards umożliwiające analizę cen noclegów Airbnb w Barcelonie, Berlinie i Budapeszcie oraz czynników wpływających na te ceny. Stworzono slicery umożliwiające filtrowanie danych według miasta, typu dnia oraz rodzaju obiektu (rysunek 9).

Miasto	Typ dnia	Rodzaj obiektu
<input type="checkbox"/> Barcelona	<input type="checkbox"/> Dzień roboczy	<input type="checkbox"/> Cały dom/apartament
<input type="checkbox"/> Berlin	<input type="checkbox"/> Weekend	<input type="checkbox"/> Pokój prywatny
<input type="checkbox"/> Budapest		<input type="checkbox"/> Pokój współdzielony

Rysunek 9. Slicery

Średnia cena noclegów jest najwyższa w Barcelonie i wynosi 313,13 € (rysunek 10). Natomiast najtańsze noclegi są w Budapeszcie – 211,04 € (rysunek 10). Barcelona posiada najwyższe skrajne ceny, co świadczy o obecności ofert luksusowych. Znajduje się tam najdroższy obiekt spośród analizowanych miast. Trzeba za niego zapłacić 6 950,64 € za noc (rysunek 11). Natomiast najtańszy obiekt jest w Budapeszcie i kosztuje 38,99 € za noc (rysunek 11).




Rysunek 10. Średnie ceny noclegów w Barcelonie, Berlinie i Budapeszcie

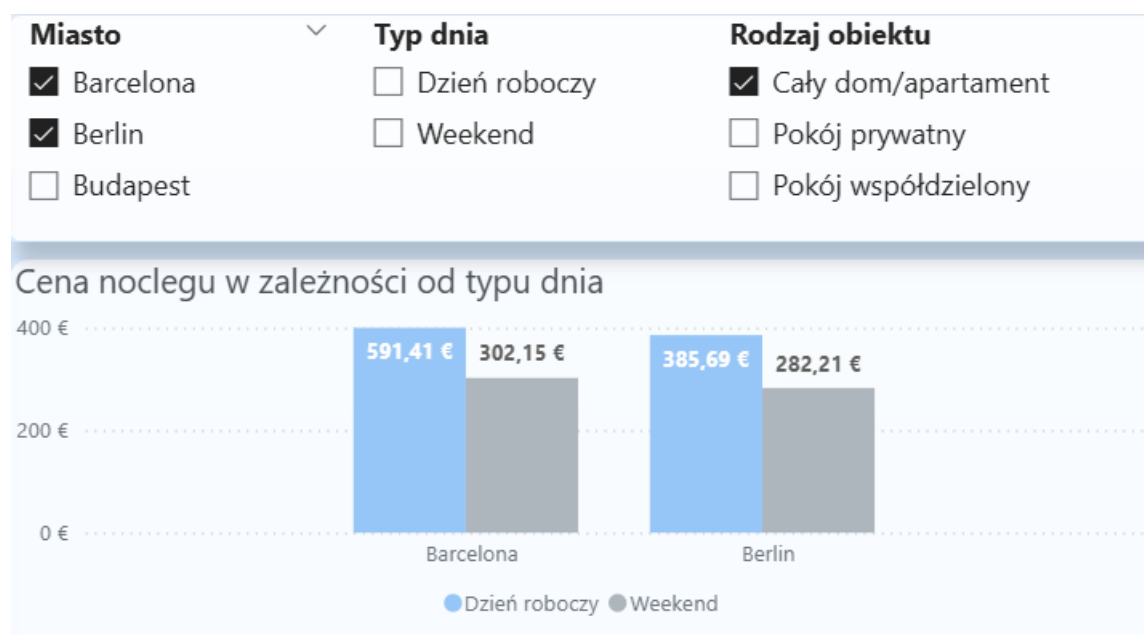
Miasto	Maksymalna cena noclegu	Minimalna cena noclegu
Budapest	3 773,64 €	38,99 €
Berlin	5 938,49 €	75,81 €
Barcelona	6 950,64 €	77,11 €

Rysunek 11. Maksymalne i minimalne ceny za obiekt w poszczególnych miastach

We wszystkich miastach ceny w weekendy (bez nałożonych filtrów na rodzaj obiektu) są wyższe niż w dni robocze. Przykładowo w Barcelonie w dzień roboczy średnia cena noclegów wynosi 307,71 €, a w weekendy 319,72 € (rysunek 12). Zjawisko to wynika z większego popytu turystycznego w weekendy. Co ciekawe w Barcelonie i Berlinie wynajęcie całego domu/apartamentu jest droższe w dni robocze niż w weekendy (rysunek 13). Może to być spowodowane dominacją turystyki biznesowej, ponieważ w dużych metropoliach takich jak Berlin czy Barcelona, ogromną część rynku stanowią podróże służbowe, delegacje oraz konferencje. Często również właściciele obiektów celowo ustawiają wyższe stawki za pojedyncze noce w tygodniu, aby zachęcić do dłuższych rezerwacji.

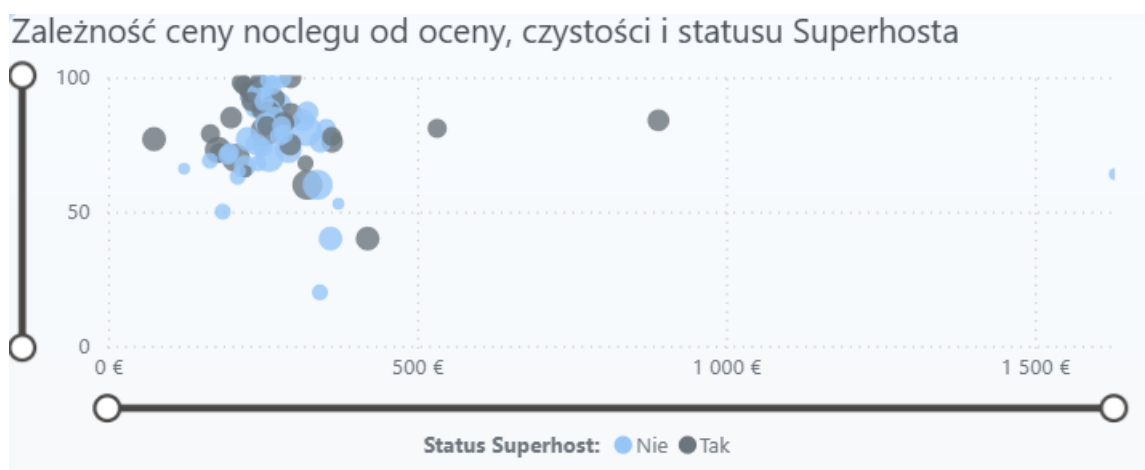


Rysunek 12. Cena noclegu w zależności od typu dnia



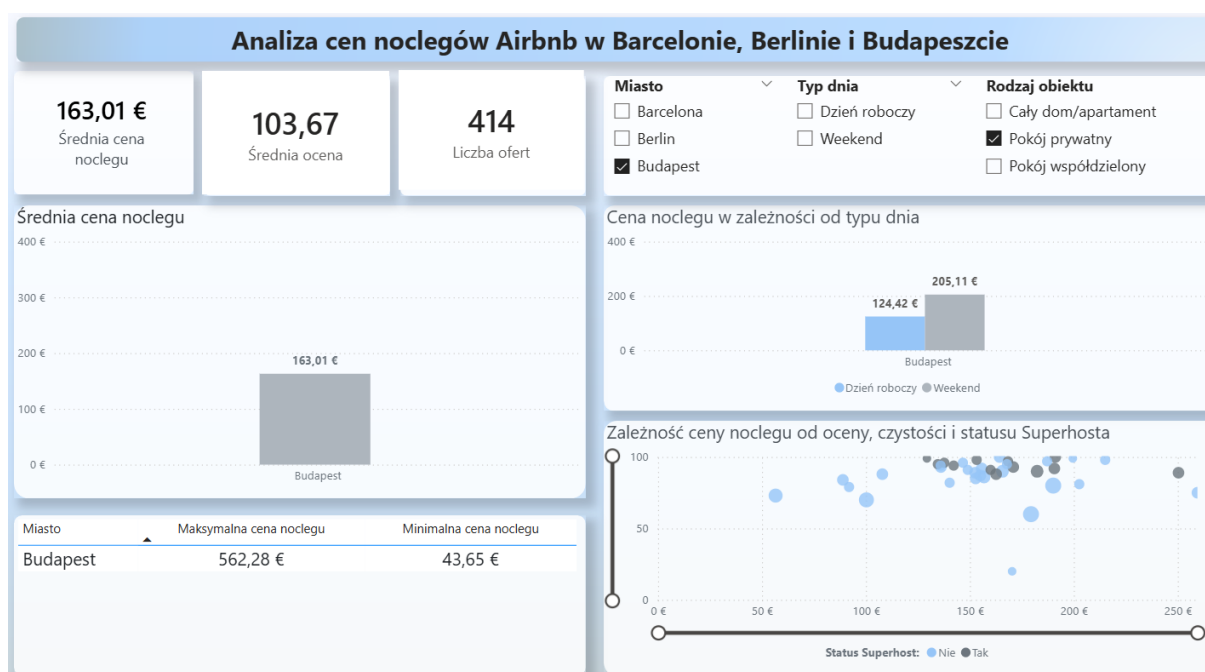
Rysunek 13. Cena noclegu w zależności od typu dnia tygodnia dla Barcelony i Berlina

Wykres zależności ceny od oceny, czystości i statusu *superhosta* pokazuje, że obiekty z wyższą oceną i czystością osiągają wyższe ceny. Status *superhost* jest powiązany z wyższymi cenami noclegów oraz wysoka jakość usług pozwala właścicielom stosować wyższe stawki (rysunek 14).



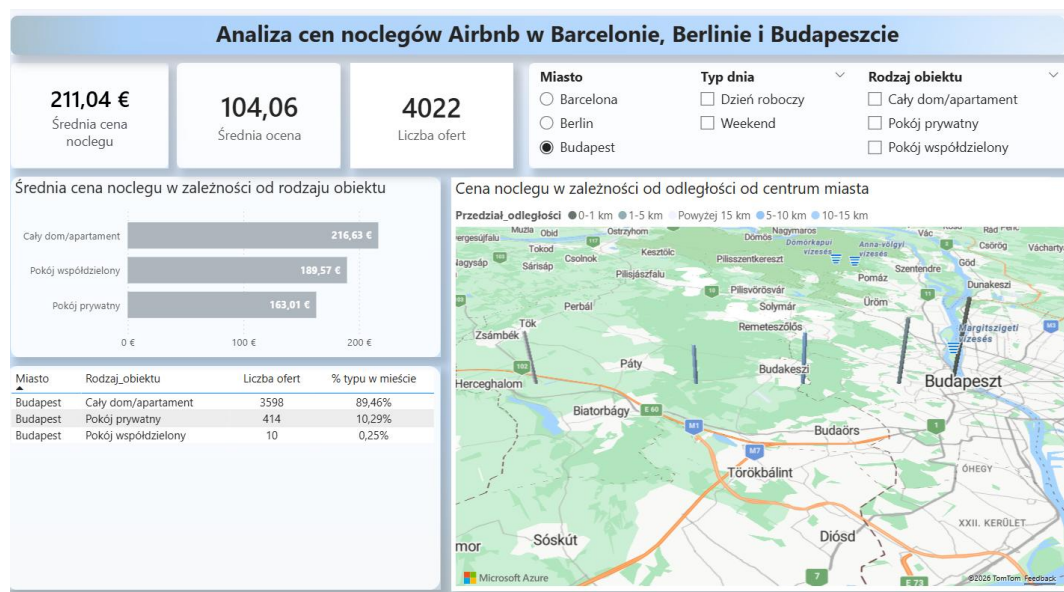
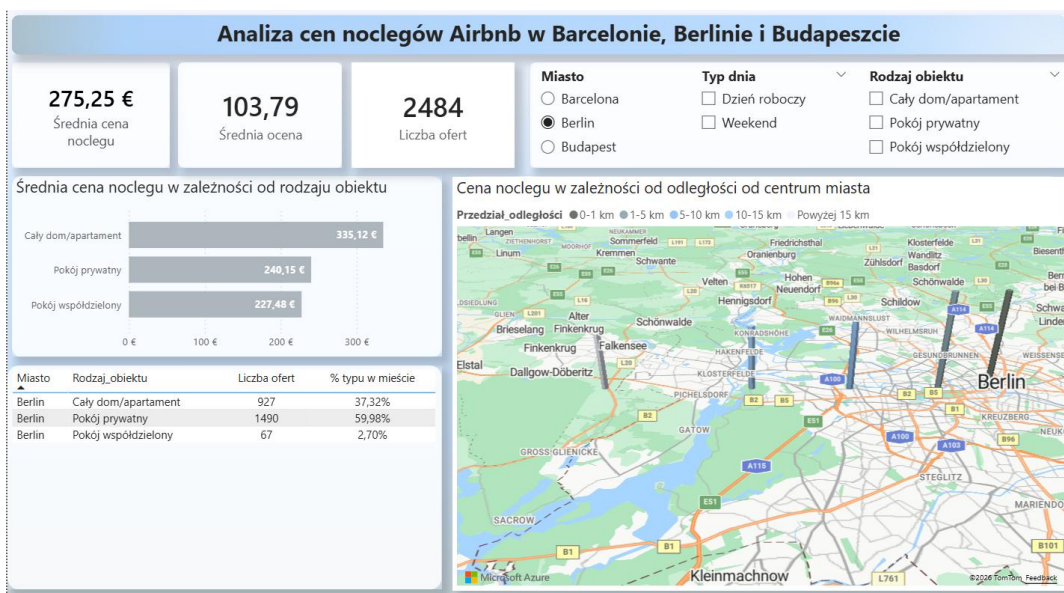
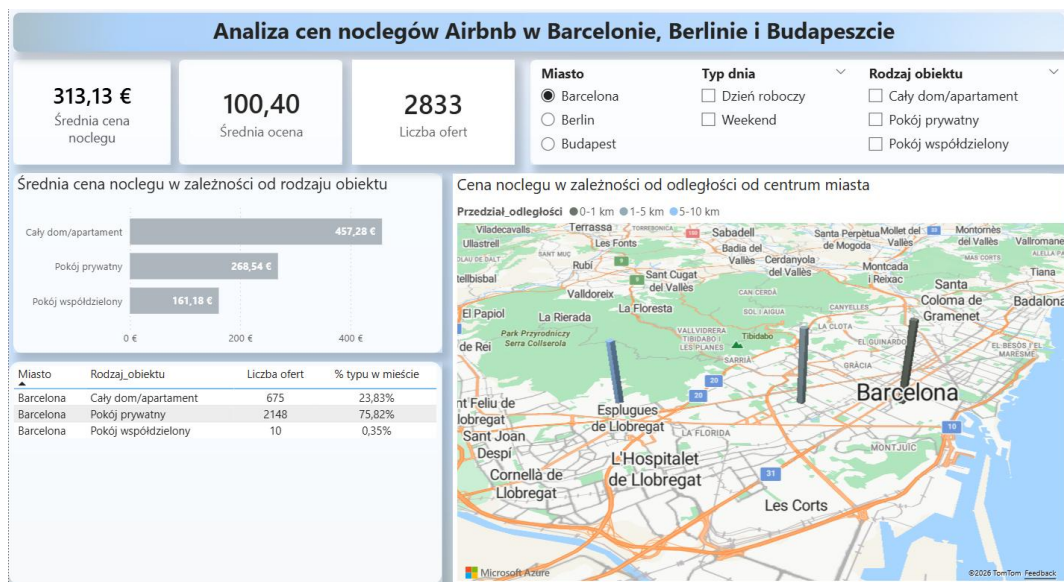
Rysunek 14. Zależność ceny noclegu od oceny, czystości i statusu *superhosta*

Po nałożeniu filtrów na dashboardzie można obserwować jak zmienia się średnia ocena, liczba ofert oraz średnia cena noclegów w zależności od miasta, typu dnia oraz rodzaju obiektu (rysunek 15).



Rysunek 15. Ceny pokoi prywatnych w Budapeszcie

We wszystkich trzech miastach najdroższe jest wynajęcie całego domu/apartamentu. Również bliskość centrum miasta wpływa na wyższą cenę noclegów. W Barcelonie i Berlinie można znaleźć najwięcej ofert pokoi prywatnych. Jest to odpowiednio 2 148 ofert i 1 490 ofert. Natomiast w Budapeszcie przeważają oferty całych domów/apartamentów – 3 598 ofert (rysunek 16).



Rysunek 16. Ceny noclegów w zależności od rodzaju obiektu, odległości od centrum miasta i liczba ofert

## 7. Wnioski

Na podstawie przeprowadzonej analizy można stwierdzić, że cena noclegu Airbnb nie jest determinowana jednym czynnikiem, lecz wynika z współdziałania wielu zmiennych rynkowych, lokalizacyjnych oraz jakościowych.

Najwyższe ceny w Barcelonie wskazują, że rynek Airbnb jest silnie powiązany z atrakcyjnością turystyczną miasta, poziomem zamożności odwiedzających i skalą popytu na krótkoterminowe noclegi. Barcelona jest miastem typowo turystycznym o bardzo dużym ruchu międzynarodowym. Pozwala to właścicielom na stosowanie wyższych cen niż w Berlinie czy Budapeszcie. Budapeszt, mimo dużej atrakcyjności, funkcjonuje w innej strefie cenowej Europy, co bezpośrednio przekłada się na niższe stawki. Oznacza to, że lokalny rynek i charakter miasta determinują bazowy poziom cen, od którego dopiero działają pozostałe czynniki.

Różnice cen między całym apartamentem a pokojem prywatnym są bardzo wyraźne. Wynajem całego obiektu zapewnia prywatność, pozwala na zakwaterowanie większej liczby osób i jest preferowany przez turystów oraz rodziny. To powoduje, że ten typ oferty jest traktowany jako produkt premium. Co istotne, mimo że większość ofert stanowią pokoje prywatne, to całe apartamenty generują najwyższe przychody jednostkowe.

Obiekty położone w promieniu do 1 km od centrum wszystkich analizowanych miast osiągają najwyższe ceny, ponieważ minimalizują czas przemieszczania się turystów, znajdują się w pobliżu atrakcji turystycznych i są bardziej pożądane logistycznie. Spadek ceny wraz ze wzrostem odległości ma charakter niemal liniowy, co wskazuje na bardzo racjonalne zachowanie rynku. Wyjątkiem są obiekty powyżej 15 km od centrum w Budapeszcie, gdzie ceny są nieco wyższe, co wynika z bliskości dużego turystycznego jeziora.

Wzrost cen w weekendy pokazuje, że rynek Airbnb reaguje dynamicznie na zmiany popytu. Weekendy są okresem wzmożonego ruchu turystycznego, dlatego właściciele stosują wyższe ceny. Widać tu, że portal Airbnb stosuje dynamiczną politykę cenową.

Użytkownicy obiektów patrzą również na oceny innych gości, ocenę czystości obiektów oraz to, czy dany właściciel ma status *superhosta*. Wynajmujący są skłonni płacić więcej za gwarancję jakości i czystości. Można również stwierdzić, że wysoka jakość usług przekłada się bezpośrednio na możliwość podniesienia ceny.

Rynek noclegów w Barcelonie, Berlinie i Budapeszcie jest dość mocno zróżnicowany cenowo. Mimo że dominują pokoje prywatne (np. 75% w Barcelonie), to nie one kształtują średnią cenę rynku. Oznacza to, że niewielka liczba drogich apartamentów znacząco podnosi średnią cenę.

Po analizie maksymalnych cen noclegów można zauważyć, że na portal Airbnb posiada w swojej ofercie nie tylko segment tanich noclegów, ale także segment premium.

Warto zauważyć, że najwyższe ceny osiągają obiekty, w których kilka czynników zostało skumulowanych (odpowiednia lokalizacja, odpowiedni typ obiektu, położenie blisko centrum, wysokie oceny, status *superhosta*, wynajem weekendowy).

Podsumowując, portal Airbnb funkcjonuje analogicznie do profesjonalnego rynku hotelarskiego. Zachowuje się zgodnie z zasadami ekonomii popytu i podaży, odpowiednio

reagując na jakość usług i dobrą lokalizację. Stosuje również dynamiczne ceny oraz posiada w swojej ofercie segmentację cenową: segment ekonomiczny, standardowy oraz premium. Ceny noclegów są wynikiem synergii czynników lokalizacyjnych, jakościowych oraz rynkowych. Największy wpływ ma miasto oraz rodzaj obiektu, natomiast pozostałe czynniki modulują cenę w zależności od atrakcyjności oferty.

Przeprowadzona analiza potwierdza, że dane z platform współdzielenia ekonomii mogą być skutecznie analizowane narzędziami Business Intelligence, a Power BI umożliwia identyfikację realnych mechanizmów rynkowych na podstawie danych empirycznych.

## **8. Bibliografia**

1. <https://www.kaggle.com/datasets/thedevastator/airbnb-prices-in-european-cities/data>  
[dostęp: 09.02.2026].



## 9. Spis rysunków

Rysunek 1. Pliki i atrybuty danych niezbędnych do analizy.....	4
Rysunek 2. Atrybuty i rekordy wybranej bazy danych.....	5
Rysunek 3. Przykładowy plik .csv z bazy danych .....	6
Rysunek 4. Dane po zaimportowaniu do Power Query .....	6
Rysunek 5. Dane po oczyszczeniu, przekształceniu i połączeniu w Powe Query .....	7
Rysunek 6. Tabela faktów i tabele wymiarów .....	8
Rysunek 7. Model gwiazdy .....	8
Rysunek 8. Kolumny obliczeniowe i miary dodane do modelu .....	9
Rysunek 9. Slicery.....	10
Rysunek 10. Średnie ceny noclegów w Barcelonie, Berlinie i Budapeszcie .....	10
Rysunek 11. Maksymalne i minimalne ceny za obiekt w poszczególnych miastach .....	10
Rysunek 12. Cena noclegu w zależności od typu dnia.....	11
Rysunek 13. Cena noclegu w zależności od typu dnia tygodnia dla Barcelony i Berlina .....	11
Rysunek 14. Zależność ceny noclegu od oceny, czystości i statusu superhosta.....	12
Rysunek 15. Ceny pokoi prywatnych w Budapeszcie .....	12
Rysunek 16. Ceny noclegów w zależności od rodzaju obiektu, odległości od centrum miasta i liczba ofert.....	13